

大模型用量与成本分析

2026.08 — 2026.09 | 华南文研 AI 助教

6,007

总请求次数

11.2 亿

总 Token

98.5%

缓存命中率

¥119.23

总成本

一、用量概览

2026 年 8—9 月共发起 6,007 次 API 调用，累计处理 token 11.2 亿。

- 输出 Token：583 万（占比约 0.5%）
- 输入缓存命中：10.99 亿（占比 98.0%）
- 输入未命中：1,677 万（占比 1.5%）

缓存命中率 98.5%，是单次成本被大幅压低的关键。

二、成本结构

两个月总成本 ¥119.23，单次请求成本约 ¥0.02。

维度	明细	占比/数值
按月	8 月 ¥71.24 (4,704 次) 9 月 ¥47.99 (1,303 次)	—
按模型	deepseek-v4-flash：¥85.99 (5,226 次)	72.1%
	deepseek-flash：¥21.31 (689 次)	17.9%
	deepseek-v4-pro：¥11.92 (92 次)	10.0%

三、关键洞察

1. 缓存命中是最大成本杠杆：命中单价约为未命中的 1/50，98.5% 的命中率把输入成本压到极低。
2. 成本随调用量波动：8 月 4,704 次、¥71.24；9 月收敛到 1,303 次、¥47.99，单次稳定在 ¥0.02。
3. v4-pro 单价高、用量少：92 次即产生 ¥11.92，单次约 ¥0.13，应只保留给高难度任务。

四、优化建议

1. 提升缓存命中：优化提示词与上下文组织，减少未命中输入，进一步压低输入成本。
2. 模型分级路由：简单问答走 flash，常规任务走 v4-flash，复杂论述/批改走 v4-pro。
3. 成本监控：设置日成本阈值与异常调用告警，及时止损。